

Predição

Juan G. Colonna
juangcolonna@uea.edu.br

Séries de tempo

Uma série temporal (ou série de tempo) é uma sequência de pontos de dados (observações) coletados, registrados ou medidos em intervalos de tempo sucessivos e ordenados. Em termos simples, é um registro de como uma variável muda ao longo do tempo.

Características Principais: A característica que define uma série temporal e a diferencia de outros conjuntos de dados é a dependência temporal. Isso significa que a ordem das observações é crucial.

- **Ordem:** A ordem dos dados importa. O valor de hoje pode depender do valor de ontem. Embaralhar os dados destruiria a informação contida neles.
- **Tempo:** Cada ponto de dado tem um "carimbo de tempo" (timestamp) associado.
- **Frequência:** As medições são geralmente feitas em intervalos regulares, conhecidos como frequência (ex: a cada segundo, hora, dia, mês, trimestre, ano).


Séries de tempo

Por que as Séries Temporais são Usadas?

O principal objetivo de estudar séries temporais é entender o comportamento passado de uma variável para:

- **Fazer Previsões (Forecasting):** Estimar valores futuros. (Ex: Prever o preço de uma ação amanhã, prever a demanda de energia elétrica no próximo mês).
- **Identificar Padrões:** Encontrar estruturas nos dados, como:
 - Tendência (Trend): O movimento de longo prazo da série (ex: a população de um país está crescendo ao longo das décadas).
 - Sazonalidade (Seasonality): Flutuações regulares e previsíveis que ocorrem em períodos fixos (ex: vendas de sorvete aumentam todo verão; tráfego de varejo aumenta todo dezembro).
 - Ciclos (Cycles): Padrões de subida e descida que não têm um período fixo, geralmente associados a ciclos de negócios (ex: recessões econômicas).


Forecasting (predição)



Janelas deslizantes e rótulos

GOLD	
Date	
2000-01-09	282.65
2000-01-16	284.40
2000-01-23	289.60
2000-01-30	286.60
2000-02-06	284.90
...	...
2023-07-09	1928.30
2023-07-16	1961.70
2023-07-23	1970.90
2023-07-30	1962.20
2023-08-06	1939.00


O rótulo de treinamento é o valor da própria série no futuro.



Janelas deslizantes e rótulos

time ↓


GOLD	
Date	
2000-01-09	282.65
2000-01-16	284.40
2000-01-23	289.60
2000-01-30	286.60
2000-02-06	284.90
...	...
2023-07-09	1928.30
2023-07-16	1961.70
2023-07-23	1970.90
2023-07-30	1962.20
2023-08-06	1939.00



Janelas deslizantes e rótulos

GOLD	
Date	
2000-01-09	282.65
2000-01-16	284.40
2000-01-23	289.60
2000-01-30	286.60
2000-02-06	284.90
...	...
2023-07-09	1928.30
2023-07-16	1961.70
2023-07-23	1970.90
2023-07-30	1962.20
2023-08-06	1939.00

Não podemos simplesmente fazer uma partição aleatória dos dados (tipo `train_test_split`), pois vai alterar a ordem temporal do treinamento




Janelas deslizantes e rótulos

Temos que reorganizar o dataset criando as colunas com deslocamento temporal, por exemplo agregar uma coluna adicional como rótulo.

time ↓

	GOLD		
Date			
2000-01-09	282.65	284.40	289.60
2000-01-16	284.40	289.60	286.60
2000-01-23	289.60	286.60	284.90
2000-01-30	286.60	284.90	...
2000-02-06	284.90	...	1928.30
...	...	1928.30	1961.70
2023-07-09	1928.30	1961.70	1970.90
2023-07-16	1961.70	1970.90	1962.20
2023-07-23	1970.90	1962.20	1939.00



Estacionariedade

O teste KPSS (Kwiatkowski–Phillips–Schmidt–Shin) serve para verificar se a sua série temporal é estacionária.

Em termos simples, uma série "estacionária" é aquela cujas propriedades estatísticas (como a média e a variância) não mudam ao longo do tempo. Ela flutua em torno de uma média constante e não apresenta uma tendência clara de subida ou descida.

- A grande maioria dos modelos estatísticos de previsão (como ARIMA, SARIMA, etc.) exige que a série temporal seja estacionária para funcionar corretamente.
- Se você usar um modelo desses em dados não estacionários, as previsões serão estatisticamente inválidas (chamadas de "regressão espúria") e não serão confiáveis.

Portanto, você usa o teste KPSS para diagnosticar se a sua série está "pronta" para a modelagem ou se precisa ser transformada primeiro.

Estacionariedade

O teste KPSS é um pouco diferente de outros testes, como o ADF (Augmented Dickey-Fuller). A sua interpretação depende da hipótese nula.

- Hipótese Nula (H_0): A série É estacionária.
- Hipótese Alternativa (H_1): A série NÃO É estacionária (possui raiz unitária).

Se o resultado for P-value < 0.05 ou 0.01 a hipótese nula deve ser rejeitada. Isso significa que a sua série temporal NÃO é estacionária.

Quando uma série não é estacionária, a solução mais comum é aplicar a diferenciação. Isso significa transformar a série, substituindo cada valor pela diferença entre ele e o valor anterior ($Y_t - Y_{t-1}$).

Isso geralmente remove a tendência  ou a aleatoriedade  e torna a nova série estacionária.

Atividade

Predecir o valor do Ouro usando o valor deste nos dias anterior e retrasado.

https://colab.research.google.com/drive/1G3G1ikkX07nxQqat1VoE_DDxwflwedNF?usp=sharing

Realizar uma predição similar, mas usando outra commodity do mesmo conjunto de dados.

Ada Boost Regressor

O AdaBoostRegressor é um poderoso algoritmo de ensemble. O nome se divide em duas partes:

- Regressor: Informa que seu objetivo é prever um número (ex: 150.50, -10, 2000) em vez de uma categoria (ex: "gato", "cachorro", "spam").
- AdaBoost: Significa Adaptive Boosting (Reforço Adaptativo). Esta é a técnica de ensemble que o torna especial.

A ideia central do AdaBoost é construir um modelo forte combinando vários modelos "fracos" de forma sequencial, onde cada novo modelo foca em corrigir os erros dos modelos anteriores.

Ada Boost Regressor


O AdaBoostRegressor (especificamente o algoritmo AdaBoost.R2 usado pelo scikit-learn) segue esta lógica:

- **Inicialização:** Todos os pontos de dados (amostras) começam com o mesmo peso.
- **Treinamento (Iteração 1):** Um modelo fraco (por padrão, uma Árvore de Decisão com `max_depth=3`) é treinado nos dados.
- **Cálculo do Erro:** O modelo faz previsões. O algoritmo calcula o erro para cada ponto de dado L_i .
- **Atualização dos Pesos (Adaptação):** Os pesos das amostras são atualizados. As amostras onde o modelo teve um erro maior (L_i) recebem um peso maior para a próxima iteração. Amostras que o modelo acertou recebem um peso menor.
- **Treinamento (Iteração 2):** Um novo modelo fraco é treinado. Mas, desta vez, o algoritmo de treinamento é forçado a prestar mais atenção às amostras de "peso maior" (aquelas que o modelo anterior errou).
- **Cálculo do Peso do Modelo:** O algoritmo também calcula um "peso de voto" (α) para o modelo que acabou de ser treinado, com base em seu erro total. Modelos com menor erro total terão um α maior.
- **Repetição:** Os passos 3-6 são repetidos por um número $n_{\text{estimators}}$ (ex: 50, 100 vezes).

Previsão Final: A previsão final é a média ponderada de todos os $n_{\text{estimators}}$ modelos, usando o "peso de voto" (α) de cada um.



Time Series Split

O objetivo **TimeSeriesSplit** é particionar os dados para validação cruzada (cross-validation) quando a ordem dos dados importa, como em séries temporais. Diferente da validação cruzada padrão (como o K-Fold), que embaralha os dados, o **TimeSeriesSplit** nunca usa dados do "futuro" para treinar um modelo. O conjunto de treino sempre vem cronologicamente *antes* do conjunto de teste.



Time Series Split

TimeSeriesSplit Com histórico de tamanho fixo.



Atividade

Realizar o `TimeSeriesSplit` com um gap de 48h para a predição.