

# Regressão


Juan G. Colonna  
juangcolonna@uea.edu.br

# Regressão linear

Assim como o Naive Bayes (discutido na aula anteriormente) é um bom ponto de partida para tarefas de classificação, os modelos de regressão linear são um bom ponto de partida para tarefas de regressão.

Esses modelos são populares porque podem ser ajustados muito rapidamente e são muito interpretáveis.


Considere um conjunto de observações com pares  $(x,y)$



# Regressão linear

Com certeza o modelo de regressão mais simples conhecido por todos é  $y = a x + b$

Num problema de regressão o desafio é encontrar os melhores valores de 'a' e 'b'




# Regressão linear

No entanto, o estimador 'LinearRegression' é muito mais capaz do que isso — além de ajustes simples de linha reta, ele também pode lidar com modelos lineares multidimensionais da forma

$$y = a_0 + a_1 x_1 + a_2 x_2 + a_3 x_3 + \dots$$


Por exemplo, considerando uma matriz de dados  $X$  com múltiplas colunas  $x_1$ ,  $x_2$ , etc Geometricamente, isso é semelhante a ajustar um plano a pontos em três dimensões ou a ajustar um hiperplano a pontos em dimensões superiores. A natureza multidimensional dessas regressões as torna mais difíceis de visualizar.



# Regressão linear

O estimador 'LinearRegression' serve para ajustar retas, planos ou hiperplanos aos nossos dados.

Ainda parece que essa abordagem se limitaria a relações estritamente lineares entre variáveis, mas também podemos flexibilizar isso.



# Regressão linear

O truque que vamos usar para adaptar a regressão linear a relações não lineares entre variáveis é transformar os dados de acordo com **funções base**. A ideia é pegar nosso modelo linear multidimensional:


$y = a_0 + a_1 x_1 + a_2 x_2 + a_3 x_3 + \dots$  e construir  $x_1, x_2, x_3$ , e assim por diante, a partir de nossa entrada unidimensional  $x$ .

Ou seja, consideramos  $x_n = f(x)$ , onde  $f()$  é uma função que transforma nossos dados.

Por exemplo, se  $f(x) = x^n$ , nosso modelo se torna uma regressão polinomial:

$$y = a_0 + a_1 x + a_2 x^2 + a_3 x^3 + \dots$$


Observe que este ainda é um modelo linear, a linearidade se refere ao fato de que os coeficientes 'a' nunca se multiplicam ou se dividem.



# Regressão linear

No Sklearn vamos usar a função de engenharia de features 'PolynomialFeatures'.

E podemos integrá-la diretamente dentro do 'sklearn.pipeline'




# Regressão linear

No Sklearn vamos usar a função de engenharia de features 'PolynomialFeatures'.

E podemos integrá-la diretamente dentro do 'sklearn.pipeline'

Mudando a função de transformação, de polinomial para gaussiana podemos ajustar curvas mais complexas.

Entretanto, curvas muito complexas podem causar sobre ajuste, e gerar resultados ruins para dados que não estão no conjunto de treinamento.





# Prever o número de viagens de bicicleta pela Ponte Fremont

[https://colab.research.google.com/drive/1DS1DzDG31QiDKTj\\_Qp62CrXkogbddXe1?usp=sharing](https://colab.research.google.com/drive/1DS1DzDG31QiDKTj_Qp62CrXkogbddXe1?usp=sharing)

Vamos verificar se podemos prever o número de viagens de bicicleta pela Ponte Fremont, em Seattle, com base no clima, na estação do ano e em outros fatores.

Vamos juntar os dados das bicicletas a outro conjunto de dados e tentaremos determinar em que medida os fatores climáticos e sazonais, por exemplo a temperatura, precipitação e horas de luz do dia, afetam o volume de tráfego de bicicletas por este corredor.

Usaremos o serviço da [NOAA](#) para obter dados diários das estações meteorológicas.

Realizaremos uma regressão linear para relacionar informações meteorológicas e outras informações à contagem de bicicletas, a fim de estimar como uma mudança em qualquer um desses parâmetros afeta o número de ciclistas em um determinado dia.

**Em particular, este é um exemplo de modelagem estatística, na qual se assume que os parâmetros do modelo têm significado interpretável.**



# Prever o número de viagens de bicicleta pela Ponte Fremont

Quais métricas usar?

- Erro Médio Absoluto (MAE - Mean Absolute Error): Representa a média das diferenças absolutas entre os valores reais e as previsões do modelo. Ele nos dá uma ideia do erro típico que podemos esperar nas previsões, sem considerar a direção do erro (superestimação ou subestimação).

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Erro Quadrático Médio (MSE - Mean Squared Error): É a média dos erros quadrados. Ele penaliza erros maiores de forma mais significativa do que o MAE, pois os erros são elevados ao quadrado.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Raiz do Erro Quadrático Médio (RMSE - Root Mean Squared Error): É a raiz quadrada do MSE. Está na mesma unidade da variável que estamos tentando prever, o que o torna mais fácil de interpretar do que o MSE. Ele representa o desvio padrão dos resíduos (os erros de previsão).

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- $R^2$  (Coeficiente de Determinação): Indica a proporção da variância na variável de destino (tráfego total de bicicletas) que é explicada pelo modelo. Um valor de  $R^2$  próximo de 1 sugere que o modelo explica uma grande parte da variância nos dados, enquanto um valor próximo de 0 indica que o modelo explica muito pouco.



$$R^2 = 1 - \frac{MSE}{Var(y)} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

# Prever o número de viagens de bicicleta pela Ponte Fremont

[https://colab.research.google.com/drive/1DS1DzDG31QiDKTj\\_Qp62CrXkogbddXe1?usp=sharing](https://colab.research.google.com/drive/1DS1DzDG31QiDKTj_Qp62CrXkogbddXe1?usp=sharing)

Como validar um modelo de regressão?

Igual que na classificação, usando um conjunto de holdout ou uma validação cruzada.

Tarefa: estender o exemplo das bicicletas usando holdout e 5-CV. Calcular as métricas.

