

Áudio Features

Juan G. Colonna
jgcolonna@uea.edu.br

Como trabalhar com áudio e ML?

Nesta aula iremos explorar atributos comumente utilizados em classificação de áudio com machine learning

Para isso devemos primeiro entender vários conceitos de séries temporais, representação de frequências, espectrogramas, etc.

Vamos utilizar uma biblioteca adicional chamada Librosa: <https://librosa.org/>

Referencia: <https://musicinformationretrieval.com/index.html>

link do colab: https://colab.research.google.com/drive/1lqdGrHHy4_qGUXN1aeAZFeZnsEOMSz7F?usp=sharing

Atributos


Existem dois tipos de atributos:

1. Temporais:
 - a. Energia,
 - b. Zero-Crossing Rate,
 - c. autocorrelação,
 - d. etc.


2. Espectrais:
 - a. Spectral Centroid,
 - b. Bandwidth,
 - c. Pitch,
 - d. Frequência principal,
 - e. MFCCs,
 - f. etc.

Série de tempo (áudio)

O áudio é uma série de valores ordenados no tempo (série temporal). Quando carregado na memória pode ser utilizado como um vetor.




zoom



Espectro de Frequências

A transformada de Fourier permite representar um sinal temporal numa nova representação chamada espectro de frequências.

Nessa nova representação, no eixo horizontal temos as frequências do sinal e no eixo vertical temos a energia de cada frequência.




Espectro de Frequências

A transformada de Fourier permite representar um sinal temporal numa nova representação chamada espectro de frequências.

Nessa nova representação, no eixo horizontal temos as frequências do sinal e no eixo vertical temos a energia de cada frequência.


Por exemplo, a nota “La” no violão tem uma frequência com muita energia nos 110 Hz.



Espectro de Frequências

O algoritmo que utilizamos para fazer essa transformação (sair do domínio do tempo para visualizar o sinal no domínio da frequência) chamasse Fast Fourier Transform.

$$f_k = \sum_{n=0}^{N-1} x_n e^{-2\pi j \frac{kn}{N}}$$




Espectro de Frequências

O algoritmo que utilizamos para fazer essa transformação (sair do domínio do tempo para visualizar o sinal no domínio da frequência) chamasse Fast Fourier Transform.


$$f_k = \sum_{n=0}^{N-1} x_n e^{-2\pi j \frac{kn}{N}}$$

Também é possível recuperar o sinal original a partir do seu espectro de frequências:

$$x_n = \frac{1}{N} \sum_{k=0}^{N-1} f_k e^{2\pi j \frac{kn}{N}}$$




Janelamento temporal



Atributos

Spectral Centroid

$$f_c = \frac{\sum_k S(k) f(k)}{\sum_k S(k)}$$




onde $S(k)$ é a energia da frequência k e $f(k)$ é a frequência.

Atributos

Spectral bandwidth

$$\left(\sum_k S(k) (f(k) - f_c)^2 \right)^{(1/2)}$$



Atributos

Zero-Crossing:
$$ZC = \sum_{n=0}^{N-1} |\text{sgn}(x_n) - \text{sgn}(x_{n+1})|$$

Autocorrelação:
$$R_{xx} = \frac{1}{r} \sum_{n=1}^{N-r} x_n x_{n+r}; \quad r = \{0, 1, 2, \dots, N/2\}$$

A autocorrelação é usada para encontrar padrões repetidos em um sinal. Para sinais musicais, um padrão repetido pode corresponder a um período fundamental (pitch).

Pitch:
$$\text{Pitch} = \max_r R_{xx}$$

Primeira atividade

Dataset: What is a note? A collection of notes played on a guitar

<https://www.kaggle.com/juliancienfuegos/what-is-a-note>

Objetivo da atividade: explorar atributos de áudio, classificar e agrupar notas do violão.

link: https://colab.research.google.com/drive/1lqdGrHHy4_qGUXN1aeAZFeZnsEOMSz7F?usp=sharing

Observação: os conceitos aprendidos podem ser utilizados para afinar um violão, você consegue imaginar como?

Atividade proposta

Utilizando o mesmo dataset anterior e com as amostras que foram separadas para teste, realizar:

1. uma verificação das métricas Silhouette e ELbow para encontrar o melhor k.
2. depois de gerar o novo agrupamento com o melhor k, classificar as amostras que faltaram (df_test)

File	
0	(Scale1) Do.wav
1	(Scale2) Re.wav
2	(Scale3) Mi.wav
3	(Scale4) Fa.wav
4	(Scale5) So.wav
5	(Scale6) La.wav
6	(Scale7) Si.wav
7	(Scale8) Do.wav

Espectrograma

Voltando ao espectro de frequências.... Existe alguma forma de combinar o janelamento do sinal com o algoritmo FFT?

Existe sim, podemos realizar a FFT de cada janela.

Mas, para que isso seria útil?

Para poder observar as variações das frequências ao longo do tempo.

Espectrograma

Voltando ao espectro de frequências.... Existe alguma forma de combinar o janelamento do sinal com o algoritmo FFT?

Espectrograma

Voltando ao espectro de frequências.... Existe alguma forma de combinar o janelamento do sinal com o algoritmo FFT?

Existe sim, podemos realizar a FFT de cada janela temporal do sinal.

Mas, para que isso seria útil?

Espectrograma

Voltando ao espectro de frequências.... Existe alguma forma de combinar o janelamento do sinal com o algoritmo FFT?

Existe sim, podemos realizar a FFT de cada janela temporal do sinal.


Mas, para que isso seria útil?

Para poder observar as variações das frequências ao longo do tempo.

Espectrograma



From FFT to spectrogram.

1. É realizada a FFT de cada janela do sinal.
2. Cada FFT é organizada numa matriz com T colunas e F linhas (as linhas representam os bins das frequências e as colunas representam o tempo central da janela temporal).
3. A matriz pode ser vista como uma imagem na qual a intensidade dos pixels é a amplitude dos valores da FFT.



Espectrograma

From FFT to spectrogram.



link:


<https://colab.research.google.com/drive/1HxSURJ8Ju-TCGh8dAbN-9BNCwKfceS1y?usp=sharing>

Mel-Frequency Cepstral Coefficients

Para cada espectro, de cada janela, podemos aplicar o processamento ilustrado na figura.



MFCC é uma forma de reduzir informação, por exemplo: o espectro original pode ter 1024 pontos, mas podemos escolher somente 12 filtros triangulares, com isso vamos obter 12 MFCCs.

Os filtros são organizados numa escala logarítmica, estão mais juntos nas baixas frequências, permitindo ter uma melhor resolução (capturar informações mais granulares) na parte do espectro que os humanos temos mais sensibilidade auditiva.



Atributos MFCC

Se aplicarmos os MFCCs para cada janela do sinal, então podemos ter um Mel-Spectrum.



Segunda Atividade

Detectar fragmentos de uma música

1. Carregar os arquivos:
 - a. audio_brahms_hungarian_dance_5.mp3
 - b. audio_busta_rhymes_hits_for_days.mp3
2. Converter para a representação dos Mel-Spectrum
3. Treinar um classificador SVM com kernel RBF nos primeiro 30s de cada música
4. Avaliar o classificador em 10s posteriores.

link: <https://colab.research.google.com/drive/1HxFURJ8Ju-TCGh8dAbN-9BNCwKfceS1y?usp=sharing>

Atividade proposta

1. Carregar o dataset Audio Cats and Dogs (<https://www.kaggle.com/mmoreaux/audio-cats-and-dogs>)
2. Para cada áudio clip extrair um único vetor de 12 MFCCs (único!!!)
3. Utilizar a separação de treino e teste sugerida nas pastas do dataset para treinar e avaliar um classificador
4. Reportar as métricas.